Trabajo Práctico de Inteligencia Artificial

Desarrollo de la solución

El objetivo del trabajo fue construir una cartera de préstamos que maximizara la ganancia esperada sin superar el presupuesto de USD 2.000.000. Para resolverlo, primero estimamos la probabilidad de pago de cada solicitud y luego utilizamos esas probabilidades para decidir qué préstamos aprobar.

Comenzamos analizando solicitudes_train.csv, que contiene las solicitudes realizadas durante 2025. Revisamos los tipos de datos, los valores faltantes, los duplicados y la distribución de Estado_Final.. Aproximadamente el 84 % de las solicitudes fueron pagadas y el 16 % terminaron en default. También analizamos el monto solicitado, la tasa de interés, el ingreso mensual y el motivo del préstamo.

Luego incorporamos comportamiento_bancario.csv, que contiene el historial mensual de los usuarios. Ambos archivos se relacionaron mediante ID_Usuario. Para evitar data leakage, utilizamos únicamente los registros bancarios anteriores a la fecha de cada solicitud. De esta manera, el modelo no recibió información futura que no habría estado disponible al momento de tomar la decisión.

A partir del historial bancario construimos cuatro variables principales: cantidad de meses disponibles, saldo promedio anterior a la solicitud, promedio de días de atraso en otras deudas y atraso máximo registrado. Estas variables se unieron con los datos originales para representar tanto las características del préstamo como el comportamiento financiero previo del solicitante.

Modelado y experimentación

El primer modelo utilizado fue una Regresión Logística. Se eligió como punto de partida porque es sencilla de interpretar y permite obtener directamente una probabilidad de pago. Este modelo alcanzó un ROC-AUC cercano a 0,845 y sirvió como referencia para comparar los siguientes experimentos.

Posteriormente probamos Random Forest, Decision Tree y Gradient Boosting. Para que la comparación fuera razonable, mantuvimos las mismas variables de entrada y una separación similar entre entrenamiento y validación. Durante las pruebas observamos que una mejora en las métricas predictivas no siempre producía una mayor ganancia. Por ese motivo, además de evaluar la capacidad de clasificación, analizamos el resultado económico obtenido por cada cartera.

En el caso de DecisionTreeClassifier, modificamos principalmente max_depth y min_samples_leaf. Esto permitió controlar la complejidad y reducir el riesgo de sobreajuste. Una de las configuraciones evaluadas utilizó max_depth = 8 y min_samples_leaf = 600. Después de cada cambio volvimos a entrenar el modelo y comparamos tanto las métricas como la rentabilidad.

Selección de la cartera

Una vez estimada la probabilidad de pago, calculamos la ganancia esperada de cada solicitud. Si el préstamo era pagado, la ganancia correspondía al monto multiplicado por la tasa de interés. Si entraba en default, se perdía el capital prestado. La fórmula utilizada fue:

Ganancia esperada = P(pago) × Monto × Tasa − P(default) × Monto

Después calculamos la rentabilidad esperada en relación con el monto solicitado y ordenamos los préstamos desde los más convenientes hasta los menos convenientes. La cartera se construyó incorporando solicitudes en ese orden, siempre que el monto acumulado no superara USD 2.000.000. Por lo tanto, una solicitud no era aprobada únicamente por tener una probabilidad alta de pago: también se consideraba cuánto podía generar en relación con el capital y el riesgo asumido.

El procedimiento se validó con solicitudes históricas cuyo resultado real era conocido. Esto permitió comparar la ganancia esperada con la ganancia que efectivamente habría obtenido la cartera. Una vez seleccionado el modelo, se volvió a entrenar utilizando todos los datos etiquetados y se generaron probabilidades para las solicitudes de enero de 2026. Finalmente, se creó el archivo de entrega con ID_Solicitud y Decision_Aprobacion, donde 1 indica aprobación y 0 rechazo.

Enfoques alternativos

También realizamos una prueba utilizando OneHotEncoder para incorporar Motivo_Prestamo. Esta transformación crea una variable binaria para cada categoría y evita asignar un orden artificial entre motivos como consumo, vivienda o salud. En esta variante se agregaron variables bancarias recientes relacionadas con saldos y atrasos, y se entrenó nuevamente Gradient Boosting aplicando la misma lógica económica de selección.

La diferencia obtenida en Kaggle entre este enfoque y el notebook principal fue de aproximadamente 2.000 puntos. La mejora o variación fue pequeña respecto del aumento de complejidad, por lo que no consideramos necesario reemplazar por completo el enfoque principal. Esta prueba mostró que agregar más variables o procesamiento no garantiza una mejora significativa.

Conclusión

El trabajo se desarrolló de forma iterativa: analizamos los datos, incorporamos el historial bancario, evitamos el uso de información futura, probamos distintos modelos y ajustamos sus parámetros. El principal aprendizaje fue que una buena métrica de clasificación no necesariamente representa una buena decisión económica. Por este motivo, la elección final no se basó únicamente en ROC-AUC u otras métricas predictivas, sino también en la ganancia obtenida por la cartera respetando el presupuesto disponible.